

למידת מכונה

פרויקט הקורס

חלק א'

קבוצה 24


ת"ז המגישים:

318903747

208214825

תאריך הגשה: 23.04.25

קישור לקולאב



תוכן עניינים

3		1. עיבוד הנתונים – Data collection and Sensing
4		2. Dataset Creation
4		2.1 Exploratory data analysis
7		2.2 Pre-processing
8		2.3 Segmentation
8		2.4 Feature extraction
11		2.5 Feature representation
11		2.6 Feature selection
11		2.7 Dimensionality reduction
12		3. Validation
13		4. נספחים

1. עיבוד הנתונים – Data collection and Sensing

1.1 ה- Data collection הוא אוסף הנתונים שמייצגים את העולם האמיתי שאותו אנחנו רוצים ללמוד. הנתונים שלנו נאספו מהרשת החברתית "X" והם כוללים entities שהם הודעות טקסט שפורסמו על ידי משתמשים שונים. כל הודעה מסווגת לפי label – הודעה חיובית או שלילית (בינארי). בתהליך ה- Sensing מודדים את הישגיות בצורה רציונלית ועקבית. תהליך זה מטרתו לקשר בין העולם האמיתי לבין ה-raw data. סוג ה- Sensing שבוצע על הדאטה הוא מסוג סטטי. החישה מסווגת כך מאחר והנתונים שנאספו אינם משתנים לאורך זמן, כלומר בכל רגע נתון נקבל את אותם המשתנים. לדוגמה: סוג ההודעה, תאריך וזמן שליחת ההודעה, מספר העוקבים של המשתמש ביום הפרסום ועוד. כלל המידע שנאסף מתאר תכונות קבועות בזמן ואין כאן מדידות שבהן הנתונים יכולים להשתנות לאורך זמן.

1.2 סוג של Sensing שלא בוצע על הדאטה הוא מסוג דינמי. ניתן לאסוף מידע דינמי על הפוסט, כמו למשל קצב הגידול בלייקים על הפוסט לאורך זמן. ניתן להוסיף מידע על כמות הלייקים העדכנית (כל 5 שעות למשל) – אנחנו מניחים שזה יאפשר לקבל הבנה עמוקה יותר של הפוסט כך שיתאפשר להבין האם היא חיובית או שלילית.


1.3 קטגוריית הלמידה במשימת הלמידה שלנו הינה מסוג Supervised Learning מכיוון שה- Labels ידועים – יש לנו משתנה מטרות ברור (sentiment), המייצג האם ההודעה חיובית או שלילית. הסיווג במשימה הוא Binary Classification שכן קיימות שתי קטגוריות בלבד. מטרת משימת הלמידה שלנו: בהינתן הודעה חדשה מהרשת החברתית, לסווג אותה כ"חיובית" או "שלילית" על בסיס המידע שנאסף. יחד עם זאת, ניתן לזהות פוטנציאל ליישום סוגים נוספים של משימות למידה. למשל ניתן לבצע Unsupervised Learning מסוג Clustering. ניתן לקבץ את ההודעות או המשתמשים לפי מאפיינים דומים, מבלי להיעזר בתוויות הקיימות. לדוגמה, ניתן לגלות קבוצות משתמשים עם דפוסי פעילות שונים – כמו משתמשים בעלי מעורבות גבוהה אך השפעה נמוכה (פוסטים עם מעט לייקים או שיתופים). סוג נוסף שניתן לבצע הוא Unsupervised Learning מסוג Anomaly detection. ניתן לזהות פוסטים חריגים, שהתנהגותם יוצאת דופן ביחס לשאר – כמו פוסט שקיבל שיתופים רבים מחשבון חדש עם מעט עוקבים.

2. Dataset creation

2.1 Exploratory data analysis

עבור אוסף הנתונים שניתן לנו, הכולל 17 משתנים וביניהם משתנה המטרה Sentiment, ביצענו ניתוח מעמיק במטרה לחשוף תובנות ראשוניות על מבנה הדאטה והקשרים שבין המשתנים. התמקדנו במיוחד בקשרים בין המשתנים השונים לבין משתנה המטרה, תוך שימוש בגרפים וסטטיסטיקות תיאוריות. בקולאב ישנם ניתוחים נוספים שנמצאו פחות רלוונטיים למשימת הלמידה, בעוד שבסעיף זה מוצגים הקשרים המרכזיים שלדעתנו עשויים לתרום ישירות למשימת הלמידה.


משתנה המטרה Sentiment



משתנה בינארי בעל שתי אפשרויות: הודעה חיובית או הודעה שלילית. ניתן לראות כי סט הנתונים יחסית מאוזן, כי אין הבדל משמעותי בין כמות ההודעות משני הסוגים. בהקשר של משימת הלמידה, מדובר במאפיין קריטי מאחר והוא משתנה המטרה שעל פיו מתבצע הסיווג. האיזון היחסי תורם לאימון מודל מדויק יחסית ולא מוטה.


משתנה Type

משתנה קטגוריאל המתאר את סוג ההודעה: פוסט, תגובה או ריטוויט. נשים לב שההתפלגות בין הסוגים אינה אחידה, כאשר הודעות מסוג תגובה הן השכיחות ביותר. בכל שלושת הסוגים קיימת




נטייה קלה לסנטימנט שלילי. בהקשר של משימת הלמידה, משתנה זה עשוי לשפר את ביצוע המודל שכן סוג ההודעה נושא מידע שעשוי להשפיע על אופי התוכן. העובדה שסוגי ההודעות אינם מאוזנים מבחינת שכיחותם מצביעה על הצורך לשקול התאמת משקל שונה לכל קטגוריה על מנת למנוע הטיה למופעים הנפוצים יותר, כמו תגובות.

משתנה Hour




ביצענו הפרדה של משתנה `post_datetime` לשעה, חודש ושנה. הגרף מציג דפוסי פעילות יומיים ברורים, עם נטייה ברורה להודעות חיוביות בשעות הבוקר ונטייה גוברת להודעות שליליות ככל שמתקרבים לשעות הערב והלילה. תבנית זו עשויה להעיד על השפעה רגשית של הזמן ביום על אופן ההתבטאות של המשתמשים. בעקבות כך, בהקשר של משימת הלמידה, מדובר בתכונה משמעותית שיכולה לתרום לדייק בזהוי הסנטימנט.

משתנה Checkmark




מהגרף עולה כי רוב המשתמשים אינם בעלי סימון אימות כלל, והם אלו שנוטים יותר לפרסם תוכן בעל סנטימנט שלילי. לעומת זאת, בקרב המשתמשים בעלי סימוני אימות – במיוחד הסימון הזהוב והאפור – קיימת נטייה ברורה יותר לסנטימנט חיובי. משתנה זה עשוי לשקף את אמינות המשתמש או את אופי החשבון, ולכן הוא בעל פוטנציאל לשפר את יכולת המודל לזהות סנטימנט באופן מדויק יותר.

משתנה Previous posts




מהגרף עולה כי הודעות חיוביות מופיעות בשכיחות גבוהה יותר אצל משתמשים שפרסמו מספר רב יותר של פוסטים בעבר, בעוד שהודעות שליליות שכיחות יותר אצל משתמשים עם מעט פוסטים קודמים. משתנה זה עשוי לרמוז על קשר בין רמת מעורבות המשתמש לבין אופי התוכן.

Followers vs Posts retweets



ניתן לראות בבירור כי ככל שמספר העוקבים עולה, כך גם מספר הריטוויטים עולה, במיוחד עבור פוסטים בעלי סנטימנט שלילי. ממצא זה מעיד על נטייה של הקהל לשתף תכנים שליליים, במיוחד ממשתמשים בעלי מספר עוקבים רב.

מטריצת קורלציה



מטריצת הקורלציה בין המאפיינים המספריים מציגה קשרים מעניינים שיכולים לתרום למשימת הלמידה. ניתן לראות מתאם גבוה מאוד בין מספר העוקבים לבין כמות הריטוויטים ומתאם גבוה גם בין עוקבים לבין כמות הלייקים. תוצאה זו מחזקת את ההנחה שמשתמשים בעלי חשיפה גבוהה נוטים לזכות ביותר אינטראקציות עם התוכן שלהם. לעומת זאת, מספר הפוסטים הקודמים כמעט ואינו מתואם עם שאר המאפיינים, מה שמעיד על כך שהוא משתנה עצמאי יחסית ויכול לספק ערך מוסף למודל.

Pre-processing 2.2

בשלב זה נבצע מניפולציות על ה-sensed raw data בכדי שנוכל להשתמש בו בצורה טובה יותר בשלבים הבאים. מהסתכלות על הנתונים, עבור עמודות ID ו-Username ראינו כי הערך בכל sample הוא ייחודי ואין שני samples עם אותו הערך עבור משתנים אלו, ומאחר ו2 העמודות לא מקנות לנו ערך מוסף עבור משימת הלמידה החלטנו להסירם.

טיפול בחזרתיות: בדקנו כפילויות על בסיס כלל העמודות, ומצאנו כי אין כפילויות ברשומות. כלומר כל שורה מייצגת דוגמה ייחודית. כתוצאה מכך, לא נדרש טיפול בהסרת רשומות כפולות בשלב זה.

טיפול בערכים חסרים – בנספח 1 ניתן לראות פלטים לפני ואחרי הטיפול בערכים החסרים.

משתנה	מספר ערכים חסרים	אחוז ערכים חסרים	אופן הטיפול	הסבר
Sentiment	527	1.32%	מחיקת הרשומות	מדובר במשתנה המטרה – לא ניתן להשתמש ברשומות חסרות סנטימנט בלמידה ולא נרצה להשלים באופן שרירותי שעלול לפגוע במסקנות שלנו.
Post_datetime	507	1.27%	מחיקת הרשומות	לא ניתן להשלים תאריך באופן שרירותי, בנוסף אלו לא רשומות מהותיות עבור הניתוח שלנו ולכן נעדיף למחוק את הרשומות החסרות.
Timezone	507	1.27%	מחיקת העמודה	מהניתוח שביצענו בשלב הEDA ראינו שאין דפוס מובהק של משתנה זה המשפיע על הסנטימנט או על משתנים האחרים. לכן נעדיף למחוק את העמודה כי היא לא תורמת לנו למשימת הלמידה.
Post_likes	486	1.21%	השלמת הערכים לפי ממוצע כולל	משתנה רציף שמעניין אותנו בניתוח הנתונים, משפיע ישירות על הבנת מעורבות המשתמש. השלמת ערכים חסרים לפי ממוצע שומרת על פיזור הנתונים הכללי ואינה יוצרת הטיה משמעותית.
Post_retweets	486	1.21%	השלמת הערכים	בדומה ללייקים, גם ריטוויטים הם מדד לאינטראקציה עם הפוסט. כיוון שמדובר במשתנה כמותי עם פיזור

רחב אך עקבי, השלמה לפי ממוצע מאפשרת שמירה על המשכיות הנתונים בלי לפגוע בתובנות מהגרפים והמודל.	לפי ממוצע כולל			
עבור 7 המשתנים, חסרים 480 ערכים, כלומר כחצי מהנתונים ברשומות אלה חסרים. השלמה של כל אחד מהנתונים יכולה להיות לא אפקטיבית, במיוחד מאחר וכל משתנה ידרוש דרך טיפול שונה לגמרי מהאחר. נדגיש גם כי 480 ערכים מתוך 40,000 יחסית זניח ועל כן אנחנו מעריכים שזה לא ישפיע על אופן הייצוג של הנתונים את העולם האמיתי.	מחיקת הרשומות.	1.2%	480	Checkmark
		1.2%	480	Account_creation_date
		1.2%	480	Email
		1.2%	480	Birthday
		1.2%	480	Followers
		1.2%	480	Profile_picture
		1.2%	480	Previous_posts_count

המרת סוגי הנתונים

בשלב זה נבצע המרה של חלק מהמשתנים לסוגים שונים שיהיה קל יותר לעבוד איתם בהמשך. המטרה היא לתקן ולהפוך את הנתונים לשמישים, ברמה של איכות הנתונים, כדי להכין את הנתונים הקיימים לשלב הבא.

המשתנים `post_likes`, `post_retweets`, `previous_posts_count` ו-`followers` הומרו למשתנים מסוג `int`.

משתנה `post_datetime` – ביצענו המרה של התאריך והשעה לפורמט מתאים מסוג `datetime`.

משתנה `account_creation_date` ומשתנה `birthday` – עבור שני המשתנים ביצענו המרה של התאריכים לפורמט מתאים מסוג `datetime`.

2.3 Segmentation

אמנם לא הוזכר כחלק מהפרויקט אך הוא אחד מששת השלבים שנלמדו בהרצאה. שלב זה עוסק בזיהוי וחילוף של אזורים רלוונטיים מתוך מידע גולמי, כמו בתמונות, קטעי קול או וידאו, כאשר רק חלק מהמידע משמש את תהליך הלמידה. במקרה שלנו, הדאטה כבר ממורכזת ומובנה היטב, כך שכל שורה מייצגת ישות שלמה (הודעה) עם משתנים תיאוריים מוכנים לניתוח. לכן, לא נדרש תהליך של קיטוע או סינון מידע, וכל הנתונים זמינים ושימיים ללמידה, ועל כן נציין כי שלב זה אינו רלוונטי.

2.4 Feature extraction

בשלב זה נרצה לחלץ פיצ'רים מהנתונים, מדובר בשלב קריטי לבניית משימת הלמידה.

פיצ'רים שקשורים למאפייני משתמש:

משתנה Sentiment – המרה למשתנה בוליאני, 1 עבור סנטימנט חיובי ו-0 עבור שלילי.
משתנה embedded_content_url – במקום שיכיל קישור/ לא יכיל, בחרנו לבצע המרה למשתנה בוליאני המציין האם צורף קישור חיצוני (1) או לא (0).

משתנה profile_picture – גם כאן המרנו את המשתנה למשתנה בוליאני המציין האם קיימת תמונת פרופיל או לא.

יצירת משתנה age – יצרנו משתנה גיל באמצעות חישוב ההפרש בין שנת הלידה לבין השנה הנוכחית. תכונה זו מאפשרת לנו ללמוד על מאפייני הגיל של המשתמשים, שעשויים להשפיע על סגנון הפוסטים שלהם והסנטימנט.

יצירת משתנה account_age_years – יצרנו משתנה שמתאר את וותק החשבון בשנים, כלומר מספר השנים שעברו מאז פתיחת החשבון. פיצ'ר זה עשוי לשקף את רמת הניסיון והוותק של המשתמש ברשת, אשר עשוי להשפיע על אופי התוכן והסנטימנט.

יצירת משתנה Email_category - הוספת עמודה של סיווג כתובות הדוא"ל לפי Personal, Business, academic ו-other (לפי סיומת הדומיין gmail, yahoo, edu וכו'). במטרה להבין את סוג המשתמש ולתרום להבנה טובה יותר של מאפייני הכותב בהקשר לסנטימנט.

פיצ'רים הקשורים לתוכן ההודעה ולזמן הפרסום:

יצירת משתנה day_of_week – יצרנו משתנה חדש שמייצג את יום השבוע בו פורסמה ההודעה (למשל: ראשון, שני וכו') מתוך משתנה התאריך. פיצ'ר זה נועד לבדוק האם קיימים דפוסים קבועים בסנטימנט לפי יום מסוים - לדוגמה, האם בימי ראשון יש יותר תוכן שלילי לעומת סופי השבוע.

יצירת משתנה is_weekend - פיצ'ר בינארי המציין האם ההודעה פורסמה בסוף השבוע (חמישי - שבת) או לא. מטרת הפיצ'ר היא לזהות שינויי התנהגות או סגנון בין ימי השבוע לסופ"ש, שעלולים להשפיע על הסנטימנט של הפוסטים.

יצירת משתנה time_of_day – הוספנו עמודה נוספת שמסווגת את שעת פרסום ההודעה לשלוש קטגוריות: בוקר,צהריים וערב. חלוקה זו בוצעה במטרה לאתר דפוסים סנטימנטליים בהתאם לזמן ביום – למשל, האם קיימת נטייה לביטויים חיוביים בבוקר ושליליים בערב.

יצירת משתנה text_length_category - יצרנו פיצ'ר שמסווג את אורכי ההודעות לפי קצר (עד 80 תווים), בינוני (בין 80 ל-140) וארוך. אורך הטקסט עשוי לשקף סגנון ביטוי שונה, ויכול לסייע בזיהוי דפוסי סנטימנט.

יצירת משתנה num_exclamations – תכונה המתארת את מספר סימני הקריאה (!) בהודעה. אנחנו מניחים כי סימני פיסוק יכולים לשמש לעיתים קרובות להבעת רגשות חזקים, התלהבות או כעס, ולכן נוכחותם עשויה להעיד על סנטימנט קיצוני – חיובי או שלילי. חישוב בוצע באמצעות פונקציית count על טקסט ההודעה.


יצירת משתנה num_hashtags - תכונה כמותית המייצגת את מספר ההאשטגים בפוסט. האשטגים משמשים להדגשת נושא מרכזי או מיקוד לקהל יעד מסוים, וייתכן שהם קשורים גם לרצון ביצירת השפעה רחבה יותר. הנתון עשוי לשקף את כוונת המשתמש ואת עוצמת המסר.

פיצ'רים הקשורים למדדי מעורבות:


משתנה likes_per_followers – יחס בין מספר הלייקים לבין מספר העוקבים של המשתמש. פיצ'ר זה משקף את רמת המעורבות היחסית של הקהל בתוכן שפורסם. יחס גבוה עשוי להעיד על תוכן מושך או מעורר רגש, שעשוי להתקשר לסנטימנט מסוים.

משתנה posts_per_followers – יחס בין כמות הפוסטים שהמשתמש פרסם בעבר לבין מספר העוקבים שלו. הפיצ'ר הזה נותן אינדיקציה לרמת הפעילות של המשתמש ביחס לחשיפה שיש לו. זה יכול לשקף דפוסי שימוש שונים – למשל, משתמשים שמעלים הרבה פוסטים למרות שיש להם מעט עוקבים.

החלטנו להשתמש גם באלגוריתם N-gram שהודגם בהרצאה, על מנת לזהות את המילים וצמדי המילים השכיחים ביותר בטקסטים. הקפדנו להסיר מילות קישור וסימני פיסוק שאינם תורמים להבנת הסנטימנט. לאחר הפעלת האלגוריתם, בחרנו להמיר את 20 המילים וצמדי המילים הנפוצות ביותר לפיצ'רים חדשים – כך שנוספו 20 עמודות חדשות לדאטהסט. כל עמודה מייצגת משתנה בינארי - האם המילה הופיעה בטקסט (1) או לא (0). ניתן לראות בתרשים את 20 המילים הנפוצות ביותר ובנוסף Word Cloud של המילים:



ביותר ובנוסף Word Cloud של המילים:



Feature representation 2.5

כעת נרצה לייצג את ערכי הפיצ'רים בצורה עקבית ואחידה, במטרה למנוע מצב שבו המודל ייתן עדיפות לפיצ'רים מסוימים רק בשל סקלת ערכים גבוהה יותר. לכן, כלל המשתנים הועברו לסקלה אחידה בטווח של 0 עד 1 – בהתאם לסוג הפיצ'ר. בנספח 2 מוצגת טבלת הנתונים לאחר הנרמול.

- משתנים קטגוריאליים הומרו כך שכל ערך אפשרי בכל משתנה הוצג כעמודה נפרדת, עם ערך 1 כאשר ההודעה שייכת לקטגוריה זו אחרת. (לדוגמה משתנה type שיכול לייצג 3 סוגים שונים, הפך ל3 עמודות נפרדות).
- משתנים נומריים – בוצע נרמול של המשתנים כך שכל הערכים יישארו בטווח של 0 עד 1, תוך שמירה על הפרופורציות היחסיות ביניהם. השתמשנו בשיטת Min-Max שמקצה ערך 0 לערכים הנמוכים ביותר, 1 לגבוהים ביותר, ולשאר מקצה ערכים יחסיים בהתאם למיקומם בתחום.
- משתנים בינאריים – המשתנים הרלוונטיים עבורם ישנן 2 אופציות (כמו Sentiment, profile_picture וכו') כבר הומרו בשלבים הקודמים לערכים בינאריים כך ש1 מייצג נוכחות של התכונה ו-0 אחרת.


Feature selection 2.6

בשלב זה נרצה לבחור את הפיצ'רים הרלוונטיים ביותר למודל הלמידה, מתוך כלל הפיצ'רים שייצרנו. בחרנו להשתמש בשיטה כמותית שמניבה ציון מספרי עבור כל פיצ'ר, המאפשר לנו לדרג ולבחור בצורה אובייקטיבית את הפיצ'רים החשובים ביותר. בחרנו בשיטה שנלמדה בהרצאה, ונחשבת לשיטה פופולרית – Fischer Score. שיטה זו בודקת עד כמה כל פיצ'ר נבדל סטטיסטית בין הקבוצות של משתנה המטרה. היא למעשה משווה בין ממוצע הערכים של כל פיצ'ר בשתי הקבוצות, תוך התחשבות גם בשונות הפנימית בתוך כל קבוצה, כך שפיצ'רים עם הבדל מובהק יקבלו ציון גבוה יותר. לאחר חישוב ציוני Fisher Score לכל הפיצ'רים, בחרנו את 25 הפיצ'רים בעלי התרומה הסטטיסטית הגבוהה ביותר לסיווג הסנטימנט (ראה נספח 3).

Dimensionality reduction 2.7

כפי שלמדנו, שלב זה הוא אינו חובה, אך הוא מאפשר לנו לייצר מספר קטן יותר של פיצ'רים ובכך לשפר את יכולות הזיהוי של המודל ולחסוך זמן וביצועים, ולכן החלטנו לבצע אותו. בחרנו את שיטת PCA שנלמדה בהרצאה בכדי להפחית את כמות המימדים שבנתונים. על גבי 25 הפיצ'רים שנבחרו, ביצענו צמצום מימדים באמצעות שיטה זו. מניתוח רכיבי השונות נמצא כי 17 רכיבים בלבד מספיקים כדי להסביר כ-93% מהשונות בדאטה. המשמעות היא שהצלחנו לשמר כמעט את כל המידע הרלוונטי, תוך צמצום מימדים משמעותי שיאפשר בניית מודל קל, מהיר

ויציב יותר. צמצום זה מאפשר לנו להקטין את ממדי הבעיה מבלי לאבד מידע מהותי, ובכך לייעל את תהליך הלמידה. הבחירה נעשתה על סמך גרף השונות המצטברת (Elbow plot), תוך שמירה על איזון בין ביצועים לפשטות. בנספח 4 ניתן לראות טבלה מפורטת.



3. Validation

שלב זה נועד להעריך את ביצועי המודל באופן מהימן ולוודא שהוא כללי מספיק, ולא מותאם רק לדאטה הספציפי של קבוצת ה-Training - על מנת להימנע ממצב של over-fitting. מתוך 3 שיטות הולדיציה שהוזכרו בהרצאה, בחרנו את שיטת k-fold. בחרנו בשיטה זו כי היא מנצלת את כל הדאטה בצורה חכמה ומובילה להערכה אמינה ויציבה יותר לעומת שיטות אחרות, למשל Holdout, שבה התוצאות תלויות מאוד באופן החלוקה, או Leave-one-out, שהיא מדויקת אך פחות יעילה מבחינה חישובית. שיטת ה-k-fold מספקת איזון טוב בין דיוק ההערכה לבין מהירות ויעילות הביצוע.

מכיוון שכמות הנתונים נראתה לנו יחסית גדולה, בחרנו ב- $K=10$ כפי שנהוג. ביצענו חלוקה ל-10 קבוצות שוות כאשר 9 מתוכן ישמשו ל-*training* והעשירית תשמש כ-*test* ובכל איטרציה תתקבל תוצאת המודל. בחרנו במדד F1-Score כמדד מרכזי, מאחר והוא נפוץ במיוחד בבעיות סיווג בינארי, במיוחד כאשר הנתונים לא לגמרי מאוזנים וכשיש חשיבות גם ל-Precision וגם ל-Recall.

בסיום התהליך התקבלו תוצאות ממוצעות של ביצועי המודל (ראה נספח 5). התוצאות שהתקבלו מעידות על ביצועים יחסית טובים ויציבים של המודל. ממוצע הדיוק עומד על 77.17%, כלומר המודל חזה את הסנטימנט בצורה נכונה ב-77.17% מהמקרים. דיוק זה מצביע על כך שהמודל מצליח לסווג את מרבית Samples בצורה נכונה. מדד Precision, שהתקבל בערך של 76.56%, מצוין כי כאשר המודל חזה שההודעה חיובית, הוא צדק בכ-76.5% מהמקרים. זה מדד חשוב במקרים בהם חשוב להימנע מזיהוי שגוי של מקרים שליליים כחיוביים. מדד Recall מלמד כי המודל הצליח לזהות כ-68.6% מהמקרים החיוביים בפועל. מדד F1 score, שהוא ממוצע הרמוני של Precision ו-Recall, עמד על 72.34% ומספק אינדיקציה כללית לאיזון בין שני המדדים. סטיות התקן בכל המדדים היו נמוכות יחסית, מה שמעיד על יציבות המודל לאורך האיטרציות.

4. נספחים

4.1 נספח 1 – טיפול בערכים חסרים. פלט שמתאר את המשתנים עבורם ישנם ערכים חסרים,

מספר הערכים החסרים ואחוז הערכים החסרים מתוך כלל הערכים, ובנוסף פלט לאחר הטיפול

בערכים החסרים:

	Column	Question Mark Count	Question Mark %
0	sentiment	527	1.32
1	timezone	507	1.27
2	post_datetime	507	1.27
3	posts_retweets	486	1.21
4	post_likes	486	1.21
5	birthday	480	1.20
6	account_creation_date	480	1.20
7	checkmark	480	1.20
8	username	480	1.20
9	previous_posts_count	480	1.20
10	followers	480	1.20
11	profile_picture	480	1.20
12	email	480	1.20

	Column	Question Mark Count	Question Mark %
0	text	0	0.0
1	sentiment	0	0.0
2	type	0	0.0
3	post_datetime	0	0.0
4	post_likes	0	0.0
5	posts_retweets	0	0.0
6	embedded_content_url	0	0.0
7	checkmark	0	0.0
8	account_creation_date	0	0.0
9	email	0	0.0
10	birthday	0	0.0
11	followers	0	0.0
12	profile_picture	0	0.0
13	previous_posts_count	0	0.0

4.2 נספח 2 – פלט של טבלת הנתונים לאחר ביצוע הנרמול (בשלב ה-Feature representation)

	sentiment	post_likes	posts_retweets	followers	profile_picture	previous_posts_count	age	account_age_years	is_weekend	num_exclamations	...	checkmark_gold	checkmark_grey	checkmark_none	day_of_week_friday	day_of_week_monday	day_of_week_saturday	day_of_week_sunday	day_of_week_thursday	day_of_week_tuesday
0	0	0.001486	0.002766	0.003304	1	0.212077	0.065934	0.443357	1	0.0	...	0	0	1	0	0	0	0	0	1
1	1	0.001141	0.000178	0.000290	1	0.000000	0.197802	0.196270	0	0.0	...	0	0	1	0	0	0	0	0	0
2	1	0.001072	0.000357	0.000425	1	0.132548	0.340659	0.360373	0	0.0	...	0	0	1	0	0	0	0	0	0
3	0	0.000277	0.000357	0.000118	1	0.000000	0.285714	0.135198	1	0.0	...	0	0	0	0	0	1	0	0	0
4	0	0.001072	0.001249	0.001068	1	0.072165	0.274725	0.311422	1	0.0	...	0	0	1	0	0	0	0	0	1
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
9995	0	0.001967	0.000714	0.000987	1	0.000000	0.219780	0.094639	0	0.0	...	0	0	1	0	1	0	0	0	0
9996	1	0.004908	0.000357	0.000941	1	0.220913	0.285714	0.311080	0	0.0	...	0	0	1	0	0	0	0	0	0
9997	0	0.028241	0.011687	0.009431	1	0.092784	0.206791	0.451282	1	0.0	...	0	0	1	0	0	1	0	0	0
9998	0	0.002662	0.000624	0.001331	1	0.092784	0.197802	0.236303	1	0.0	...	0	1	0	0	0	1	0	0	0
9999	1	0.001210	0.000357	0.000543	1	0.200295	0.120879	0.590676	1	0.0	...	0	0	1	1	0	0	0	0	0

486 rows x 57 columns

4.3 נספח 3 – Fischer Score. פלט של 25 הפיצ'רים בעלי התרומה הסטטיסטית הגבוהה ביותר

לסיווג הסנטימנט, עם הציון שקיבל כל פיצ'ר.

	Feature Name	Fisher Score
1	num_hashtags	11340.705761
2	nan	9491.173254
3	previous_posts_count	4048.084810
4	checkmark_gold	1894.253040
5	checkmark_grey	1888.721654
6	text_length_category_short	1875.700122
7	checkmark_none	1485.753551
8	text_length_category_long	1353.986259
9	time_of_day_night	1243.850869
10	time_of_day_morning	958.428408
11	posts_per_followers	440.211281
12	followers	312.700779
13	posts_retweets	291.634040
14	likes_per_followers	260.691883
15	age	225.000135
16	checkmark_blue	142.977321
17	bit	109.569501
18	feel	89.090052
19	feeling	85.245293
20	time_of_day_noon	81.616180
21	just	50.715209
22	little	49.698565
23	text_length_category_medium	39.406910
24	feel like	19.360008
25	like	9.452781

4.4 נספח 4 – PCA – הטבלה מציגה את אחוז השונות שמוסבר על ידי כל אחד מהרכיבים ואת השונות המצטברת.

	Component	Explained Variance %	Cumulative %
0	PC1	10.67	10.67
1	PC2	7.93	18.60
2	PC3	7.84	26.44
3	PC4	7.00	33.44
4	PC5	6.72	40.16
5	PC6	6.16	46.32
6	PC7	5.76	52.08
7	PC8	5.15	57.23
8	PC9	4.74	61.97
9	PC10	4.45	66.43
10	PC11	4.31	70.74
11	PC12	4.21	74.94
12	PC13	4.14	79.08
13	PC14	3.71	82.79
14	PC15	3.65	86.44
15	PC16	3.54	89.98
16	PC17	3.42	93.40

4.5 נספח 5 – תוצאות ביצועי המודל לאחר ביצוע k-fold

Model performance using 10-Fold Cross Validation:

Accuracy: 0.7717 ± 0.0076
Precision: 0.7656 ± 0.0108
Recall: 0.6858 ± 0.0126
F1: 0.7234 ± 0.0096